SÉANCE 02

PROJET FIL ROUGE

# Projet fil rouge — Séance 2 : chargement et nettoyage du jeu de données météo

## Point de départ

Le document de la séance précédente présente le projet dans son ensemble : source du jeu de données météorologique SYNOP (Météo-France), station et période retenues, structure générale des colonnes disponibles (température, pression, humidité, vent, précipitations), et trajectoire du projet sur les séances 2 à 4. Reportez-vous à ce document si vous voulez retrouver le lien vers la source des données ou revoir la vue d'ensemble du projet. Vous n'avez cependant pas encore manipulé le fichier réel.

Vous disposez maintenant des bases nécessaires pour l'aborder : lecture de fichiers, tableaux numpy et DataFrame pandas. Le fichier réel diffère de l'extrait pédagogique utilisé pendant le TP pandas sur deux points importants : il couvre une année entière au lieu de trois jours, et le nom exact de ses colonnes suit strictement la convention Météo-France ( `t` en Kelvin, `mq` pour les valeurs manquantes, séparateur `;` ).

## Objectif de la séance

Produire, dans un script ou un notebook nommé de façon stable (par exemple `projet_meteo.py` ou `projet_meteo.ipynb` — vous le réutiliserez tel quel en séance 3), un DataFrame nettoyé du jeu de données météo complet, accompagné d'une première agrégation mensuelle. Ce n'est pas encore une exploration exhaustive : il s'agit d'un point d'étape (checkpoint), pas d'un livrable définitif.

À la fin de cette séance, votre script doit permettre de répondre à des questions simples telles que « quelle est la température moyenne de chaque mois sur la période couverte ? » ou « combien de valeurs manquantes reste-t-il après nettoyage, et sur quelles colonnes ? ».

## Étapes guidées

### Étape 1 — Chargement du fichier complet

Chargez le fichier fourni pour votre station et votre période. Avant d'aller plus loin, vérifiez systématiquement :

- le nombre de lignes chargées correspond-il à ce que vous attendiez, compte tenu du pas de temps du fichier (3 heures) et de la durée de la période couverte ?
- le type de chaque colonne ( `dtypes` ) est-il cohérent avec ce que représente la colonne ? Une colonne que vous savez numérique mais qui apparaît en type texte ( `object` ) est un signal à ne pas ignorer : cherchez-en la cause avant de continuer.
- si l'ouverture du fichier échoue ou si les colonnes ne se séparent pas correctement, reprenez les réflexes installés lors du TP pandas de cette séance.

### Étape 2 — Sélection des colonnes utiles

Le fichier réel contient probablement davantage de colonnes que celles utilisées pendant le TP guidé (nébulosité, visibilité, temps présent, etc.). Interrogez-vous sur les colonnes réellement nécessaires pour la suite du projet (température, pression, humidité, vent, précipitations, et bien sûr la date) et sur l'intérêt de ne conserver qu'un sous-ensemble de colonnes à ce stade, plutôt que de manipuler l'intégralité du fichier tout au long du projet.

### Étape 3 — Conversion et plausibilité des valeurs

- La température brute est-elle exprimée dans une unité directement interprétable ? Si non, quelle transformation lui appliquer, et sur quelle nouvelle colonne plutôt que d'écraser la colonne d'origine ?
- Une fois la conversion faite, les valeurs obtenues vous semblent-elles plausibles pour la station et la période choisies ? Un test rapide (min/max de la colonne convertie) permet de repérer une éventuelle erreur de conversion ou une valeur aberrante avant d'aller plus loin.

### Étape 4 — Gestion des valeurs manquantes

- Combien de valeurs manquantes chaque colonne d'intérêt contient-elle, et dans quelle proportion par rapport au nombre total de lignes ? Une proportion très différente d'une colonne à l'autre doit orienter des stratégies différentes.
- Pour chaque colonne concernée, une suppression des lignes ( `dropna` ) est-elle acceptable, ou un remplacement ( `fillna` ) est-il préférable ? Justifiez votre choix par colonne plutôt que d'appliquer une règle unique à tout le DataFrame — la même question se posait, à plus petite échelle, dans le TP guidé de cette séance.
- Vérifiez, après nettoyage, qu'il ne reste plus de valeur manquante sur les colonnes que vous comptez utiliser dans l'agrégation de l'étape suivante.

### Étape 5 — Extraction du mois et première agrégation

- Convertissez la colonne de date dans un type exploitable, en vous assurant que le format indiqué correspond exactement à celui du fichier réel.
- Une fois le mois extrait, calculez une agrégation mensuelle simple sur au moins la température (moyenne, minimum, maximum). Le résultat vous semble-t-il cohérent avec un

cycle saisonnier attendu pour la station choisie (mois d'hiver plus froids que les mois d'été) ? Si l'ordre de grandeur ou la variation saisonnière ne correspond à rien de plausible, il est probable qu'une étape précédente (conversion d'unité, valeurs manquantes) doive être revue.

### Étape 6 — Consolidation du checkpoint

Avant la fin de la séance, relisez votre script du début à la fin en l'exécutant intégralement sur un environnement propre (redémarrez le noyau si vous travaillez en notebook). Un script qui ne fonctionne que parce que des cellules ont été exécutées dans un ordre particulier n'est pas un point de départ fiable pour la séance 3.

## Pour aller plus loin

Si vous avez terminé les étapes précédentes avec de la marge, explorez une agrégation complémentaire, par exemple par heure de la journée plutôt que par mois (cycle diurne de la température), ou une comparaison de la proportion de valeurs manquantes selon le mois de l'année. Ce travail est optionnel et ne conditionne pas le point de contrôle de fin de séance ; il ne doit pas se faire au détriment d'un DataFrame nettoyé et d'une agrégation mensuelle fonctionnels, qui restent le livrable attendu.