SÉANCE 03

PROJET FIL ROUGE

Projet fil rouge — Séance 3 : exploration visuelle et structuration du script

Point de départ

À l'issue de la séance 2, vous disposez d'un script ou notebook (`projet_meteo.py` ou `projet_meteo.ipynb`) qui :

- charge le fichier complet de votre station (séparateur `;` , valeurs manquantes `mq`) ;
- conserve les colonnes utiles et ajoute une température en degrés Celsius ;
- convertit la date en type date/heure et en extrait le mois ;
- traite les valeurs manquantes des colonnes d'intérêt ;
- calcule une agrégation mensuelle de la température (moyenne, minimum, maximum).

Si l'une de ces étapes manque, terminez-la en priorité : la suite en dépend directement. Vérifiez que le script s'exécute entièrement, du début à la fin, sur un environnement propre.

Objectif de la séance

Produire :

- au moins un graphique d'exploration pertinent, enregistré sur disque, issu de vos données ;
- une version restructurée du script, découpée en fonctions, qui valide ses entrées de façon minimale et s'exécute de bout en bout.

Le travail de la séance prépare la séance 4 : le script restructuré sera la base du projet final, et vos observations sur les relations entre variables orienteront votre choix de variables pour la régression.

Étapes guidées

Étape 1 — Évolution de la température

- Tracez la température en Celsius au cours de la période. Un graphique par point d'observation (environ 2 900 sur une année) est-il lisible ? Comparez avec un tracé de l'agrégation mensuelle : que montre l'un que l'autre masque ?

- Votre graphique a-t-il un titre, une unité sur l'axe vertical, une taille adaptée ? Un lecteur qui ne connaît pas votre script doit comprendre ce qu'il voit.
- Les valeurs manquantes que vous avez traitées en séance 2 sont-elles visibles sur la courbe ? Si oui, votre stratégie de nettoyage vous semble-t-elle toujours adaptée ?

Étape 2 — Précipitations

- Examinez d'abord les valeurs de la colonne de précipitations (minimum, maximum, proportion de zéros) avant de choisir un graphique. Y a-t-il des valeurs inattendues (négatives, extrêmes) ? Si oui, cherchez ce qu'elles représentent dans la documentation du jeu de données avant de décider de les conserver ou non.
- Quel graphique répond à la question « comment se répartissent les précipitations sur 3 heures ? » ? Quel autre répond à « quel mois est le plus pluvieux ? » Pour le second, interrogez-vous sur la bonne statistique d'agrégation : somme ou moyenne ?
- Si votre histogramme est dominé par une barre unique, réfléchissez à ce que cela dit de la distribution, et à ce qu'il faudrait filtrer ou isoler pour voir autre chose.

Étape 3 — Relations entre variables

- Calculez la matrice de corrélation entre la température et les autres variables disponibles (pression, humidité, vent). Quelles variables paraissent les plus liées à la température ?
- Pour la ou les variables les plus corrélées, tracez le nuage de points. La forme du nuage confirme-t-elle ce que suggère le coefficient ? Un nuage en bandes ou en nappes cache-t-il une structure que le coefficient seul ne montre pas (indice : à quelle échelle de temps les relevés sont-ils liés entre eux ?).
- Notez par écrit, en deux ou trois phrases, les variables que vous retiendriez pour prédire la température et pourquoi. Cette note sera réutilisée en séance 4.

Étape 4 — Enregistrement des figures

- Enregistrez chaque figure produite dans un fichier image, dans un dossier dédié (par exemple `figures/`). Ouvrez les fichiers produits pour vérifier qu'ils ne sont pas vides.
- Si un fichier est blanc, interrogez-vous sur l'ordre des appels d'enregistrement et d'affichage.

Étape 5 — Restructuration en fonctions

- Relisez votre script et identifiez ses grandes étapes : lesquelles sont indépendantes les unes des autres ? Quelles données chacune reçoit-elle, quel résultat produit-elle ?
- Découpez le script en fonctions à responsabilité unique. Interrogez-vous pour chaque fonction : reçoit-elle tout ce dont elle a besoin par ses paramètres ? renvoie-t-elle un résultat, ou affiche-t-elle seulement ? modifie-t-elle le DataFrame de l'appelant sans que ce soit voulu ?

- Chaque fonction possède une docstring décrivant ce qu'elle fait, ce qu'elle reçoit et ce qu'elle renvoie.
- Rassemblez l'enchaînement des étapes dans une fonction `main()` appelée depuis le bloc `if __name__ == "__main__":`. Les constantes (nom du fichier, dossier de sortie) sont-elles définies à un seul endroit ?
- Prévoyez que la séance 4 ajoutera des étapes (préparation des variables, régression) : votre découpage permet-il de les insérer sans réécrire l'existant ?

Étape 6 — Gestion minimale des erreurs

- Listez ce qui peut échouer ou être faux en entrée de votre script : fichier absent ou mal nommé, colonne attendue manquante, valeurs hors du plausible. Pour chacun, quelle exception Python est levée aujourd'hui, et quel message verrait un utilisateur qui n'a pas écrit le script ?
- Ajoutez une vérification pour au moins deux de ces cas. Pour chaque `try` / `except`, interrogez-vous sur la portée du `try` (aussi petite que possible) et sur l'exception interceptée (précise, jamais `except:` nu).
- Testez vos protections : renommez temporairement le fichier de données, supprimez une colonne, injectez une valeur aberrante. Votre script s'arrête-t-il avec un message compréhensible ?

Étape 7 — Vérification finale

- Redémarrez l'environnement (noyau du notebook ou nouvelle exécution du script) et exécutez tout de bout en bout. Les figures sont-elles regénérées dans le dossier prévu ?
- Vérifiez que le script ne repose sur aucune variable définie à la main dans une cellule ou un terminal.
- Conservez le fichier sous le même nom : il est le point de départ de la séance 4.

Pour aller plus loin

Si vous avez terminé avec de la marge, comparez la distribution de la température mois par mois (par exemple avec des boîtes à moustaches) ou superposez, sur une même figure à deux axes verticaux, la température et l'humidité mensuelles moyennes. Ce travail est optionnel et ne se fait pas au détriment d'un script structuré qui s'exécute correctement de bout en bout.