SÉANCE 04

PROJET FIL ROUGE

Projet fil rouge — Séance 4 : régression de la température et finalisation

Point de départ

À l'issue de la séance 3, vous disposez d'un script (`projet_meteo.py` ou notebook équivalent, même nom qu'en séance 2) qui :

- charge le fichier complet de votre station et nettoie les données (température en Celsius, date convertie, mois extrait, valeurs manquantes traitées) ;
- calcule l'agrégation mensuelle de la température ;
- produit et enregistre des graphiques d'exploration dans un dossier dédié (évolution de la température, précipitations, relations entre variables) ;
- est découpé en fonctions documentées, enchaînées par `main()`, avec une validation minimale des entrées ;
- s'accompagne d'une note de deux ou trois phrases sur les variables que vous retenez pour prédire la température.

Si une de ces étapes manque, terminez-la en priorité ou demandez le script de référence au formateur : la suite en dépend directement. Vérifiez que le script s'exécute entièrement, sur un environnement propre, avant d'ajouter quoi que ce soit.

Objectif de la séance

Produire un projet final complet, restitué oralement :

- un script structuré et documenté qui va du chargement des données à l'évaluation d'une régression linéaire de la température ;
- une interprétation critique du résultat, appuyée par au moins une figure sur les prédictions ou les erreurs ;
- votre capacité à expliquer et justifier chaque choix de code, sans aide extérieure.

Le socle (étapes 1 à 8) est obligatoire. L'extension est optionnelle et ne se fait pas au détriment d'un socle terminé et compris.

Étapes guidées

Étape 1 — Définir le problème

- Quelle est la cible ? Quelles variables explicatives comptez-vous utiliser ? Reprenez votre note de la séance 3 : les observations sur les corrélations et les nuages de points la justifient-elles toujours ?
- Pour chaque variable envisagée, demandez-vous si elle pourrait contenir, sous une autre forme, l'information que vous cherchez à prédire. Si oui, que risque-t-on ?
- Quelles variables issues de la date pouvez-vous construire (mois, heure) ? Quelle relation un modèle linéaire peut-il représenter avec elles ?
- Notez vos choix et leur justification dans le script (commentaire ou docstring de module) : vous devrez les défendre à l'oral.

Étape 2 — Préparer `X` et `y`

- Quelles colonnes doivent être numériques et sans valeur manquante pour que l'entraînement fonctionne ? Que se passe-t-il si ce n'est pas le cas ?
- Combien de lignes perdez-vous lors de la suppression des valeurs manquantes ? Cette perte est-elle négligeable ? Si elle est importante, revenez au nettoyage plutôt que de la subir.
- Vérifiez les dimensions de `X` et de `y` et l'alignement de leurs lignes.
- Rangez cette étape dans une fonction qui reçoit le DataFrame, les noms de colonnes et renvoie le résultat. Que doit-elle faire si une colonne demandée n'existe pas ?

Étape 3 — Séparer entraînement et test

- Quelle proportion réservez-vous au test, et pourquoi ?
- Votre jeu de données est une série temporelle. Un découpage aléatoire et un découpage chronologique répondent-ils à la même question ? Lequel retenez-vous, et sur quel argument ?
- Vérifiez les tailles des jeux obtenus et, si vous découpez chronologiquement, les périodes couvertes par chacun.
- Votre résultat est-il reproductible d'une exécution à l'autre ?

Étape 4 — Entraîner et prédire

- Entraînez le modèle sur le seul jeu d'entraînement. Qu'est-ce qui se passerait si le test était utilisé à cette étape ?
- Examinez ce que le modèle a appris : quelles informations sont disponibles après l'entraînement, et que signifie chacune pour votre problème ?

Étape 5 — Évaluer

- Choisissez des métriques et exprimez-les en unités compréhensibles pour un lecteur qui ne connaît pas le projet.
- Une erreur de plusieurs degrés est-elle faible ou élevée ? Par rapport à quoi la juger (amplitude des températures sur la période, résultat d'une prédiction naïve) ?
- Comparez les scores d'entraînement et de test. Si l'écart est important, que cela suggère-t-il ?
- Si votre R^2 est très proche de 1, interrogez-vous : est-ce plausible pour une prédiction de la température à partir de ces variables ?

Étape 6 — Interpréter de façon critique

- Les signes des coefficients sont-ils cohérents avec ce que vous savez du phénomène ? Peut-on les comparer entre eux ?
- Tracez et enregistrez une figure qui permet de voir où le modèle se trompe (prédictions contre valeurs réelles, ou répartition des erreurs). Les erreurs semblent-elles aléatoires ou systématiques (selon l'heure de la journée, la saison) ?
- Testez au moins une variante (retirer ou ajouter une variable, changer de découpage). Qu'est-ce qui change, et comment l'expliquez-vous ? Notez les résultats de façon à pouvoir les citer.
- Rédigez en quelques phrases les limites de votre modèle : ce qu'il permet de dire, ce qu'il ne permet pas.

Étape 7 — Intégrer au script

- Ajoutez les nouvelles étapes (préparation, entraînement, évaluation, figure) sous forme de fonctions, appelées depuis `main()`. Votre découpage de la séance 3 vous permet-il de le faire sans réécrire ce qui existe ?
- Les paramètres du modèle (variables, proportion du test, graine) sont-ils définis à un seul endroit ?
- Les nouvelles fonctions valident-elles leurs entrées (colonnes présentes, nombre de lignes suffisant) ? Que verrait un utilisateur si le fichier était vide ?

Étape 8 — Finaliser et documenter

- Le fichier commence-t-il par une description de ce qu'il fait, des données attendues et de la façon de l'exécuter ? Chaque fonction a-t-elle une docstring ?
- Vos commentaires expliquent-ils les **choix** (pourquoi ces variables, pourquoi ce découpage) plutôt que de répéter le code ?
- Redémarrez l'environnement et exécutez le projet de bout en bout : les figures sont-elles regénérées, les métriques affichées, sans manipulation manuelle ?

- Relisez chaque ligne et demandez-vous si vous sauriez expliquer son rôle et ce qui arriverait si vous la supprimiez.

Étape 9 — Préparer la restitution orale

Vous disposerez d'environ 5 minutes : exécution du script, puis questions du formateur. Préparez des réponses, de mémoire et sans assistance, à des questions de ce type :

- Pourquoi ces variables, et pourquoi pas telle autre ?
- Pourquoi séparer les données ? Pourquoi ce découpage ?
- Que signifie votre erreur moyenne ? Est-elle satisfaisante ?
- Que se passe-t-il si l'on modifie telle ligne de votre script ?
- Quelle est la principale limite de votre modèle ?

Extension optionnelle — Température et consommation électrique

Réservée aux étudiants dont le socle fonctionne et qui peuvent l'expliquer. Objectif : examiner si la température permet d'expliquer la consommation électrique journalière, en croisant vos données avec un extrait éCO2mix (RTE) fourni par le formateur.

- **Découvrir le fichier.** Quelles colonnes contient-il, quel est son pas de temps, comment la date et l'heure sont-elles codées ? Dans quel fuseau horaire ? Existe-t-il des valeurs manquantes ?
- **Passer à l'échelle du jour.** Les deux jeux n'ont pas la même fréquence. Quelle valeur journalière retenir pour la température et pour la consommation, et pourquoi ?
- **Joindre.** Quelle clé commune ? A-t-elle le même type et la même granularité des deux côtés ? Combien de lignes attendez-vous après la jointure, et combien obtenez-vous ? Un écart est-il normal ou révélateur d'un problème ?
- **Modéliser.** Appliquez votre démarche (préparation, découpage, entraînement, évaluation, référence) à la consommation en fonction de la température. Comparez avec le résultat de la température.
- **Interpréter.** Une droite est-elle adaptée sur l'année entière ? Qu'indiquent le nuage de points et les erreurs ?

Vous présenterez ce travail en complément à l'oral. Il est valorisé mais n'est pas exigé.

Pour aller plus loin

Si vous terminez avec de la marge, cherchez comment un modèle linéaire pourrait mieux rendre le caractère cyclique du mois ou de l'heure (par exemple en représentant autrement ces

variables), puis mesurez, avec la même démarche d'évaluation, si le résultat s'améliore réellement.